


Étude de la criminalité en France

Pour ce travail, nous avons choisi de travailler sur la criminalité et les facteurs qui peuvent contribuer à sa progression dans les différents départements français. Par souci d'un manque d'information concernant les départements d'outre-mer, nous avons réduit notre étude à la France métropolitaine et ses 95 départements et nous nous sommes donc posé la question : la criminalité est-elle influencée par d'autres problèmes de société ?

Pour répondre à notre problématique, nous avons tout d'abord cherché une définition appropriée pour la criminalité. Après avoir trouvé un document sur data.gouv, recensant la totalité des arrestations par départements en 2022 et leurs motifs, nous avons décidé de représenter la criminalité par les arrestations pour coups et blessures. Ce qui semble être un bon indicateur pour évaluer la violence de la population française, de plus en plus importante, notamment dans les grandes villes.

Répartition de la criminalité en France en fonction de sa médiane




En bleu foncé les départements inférieurs à la médiane et en bleu clair les départements qui lui sont supérieurs.

tranquille semble être la Vendée. En observant cette moyenne et ces informations, nous avons remarqué que les départements avec le plus fort taux de coups et blessures étaient ceux de la région parisienne et du Nord de la France.


Suite au tri et à l'analyse de cette base de données, nous avons obtenu trois types de coups et blessures recensés en taux pour mille : « coups et blessures volontaires », « coups et blessures intrafamiliaux » et « autres coups et blessures volontaires ». Pour simplifier l'étude de ces chiffres, nous avons décidé d'en faire une moyenne. En France, nous pouvons donc voir que la criminalité moyenne est de 3,19 cas recensés pour 1000 habitants alors que la médiane est à 3,08. Il y a donc plus de départements avec une très forte criminalité. C'est d'ailleurs le cas de la Seine-Saint-Denis qui enregistre 5,51 cas pour 1000 habitants sur l'année 2022, au contraire le département le plus

Boxplot Moyenne coups et blessures :




À première vue, nous avons associé cette forte criminalité dans ces départements avec l'idée que ce sont des départements plus « pauvres », où le coût de la vie est souvent plus élevé ce qui crée une disparité entre différentes catégories de la population. Nous avons donc recherché des données sur le taux de pauvreté dans les départements français sur le site des Statistiques locales de l'INSEE, nous permettant de conclure quant à la pertinence de notre première

Répartition de la pauvreté en France selon sa médiane




hypothèse. Après avoir calculé la médiane, qui est ici de 14,8 %, nous avons réparti les départements dans deux clusters : l'un regroupant les départements ayant un taux de pauvreté supérieur à la médiane (cluster 2) et l'autre un taux inférieur (cluster 1). Comme nous pouvons le voir sur la carte et comme nous nous y attendions, beaucoup de départements du Nord sont dans le deuxième cluster. Dans ce deuxième cluster, nous trouvons également la Seine-Saint-Denis ayant le plus grand taux de pauvreté et taux de coups et blessures en France métropolitaine. C'est pourquoi, nous pouvons dire que le taux de pauvreté semble être corrélé à la criminalité. D'ailleurs, grâce à un nuage de points permettant d'expliquer la criminalité par le taux de pauvreté, et en affichant les équations de régression linéaire et le coefficient de détermination, nous pouvons voir que la variable taux de pauvreté explique plus de 34 % de la variable criminalité, ce qui paraît être un bon indicateur.

Néanmoins, il serait avantageux de rajouter d'autres variables à prendre en compte pour notre étude. En effet, la criminalité ne se résume pas au taux de pauvreté. Nous avons donc décidé d'observer la criminalité à travers trois autres agrégats : le taux de chômage, la taille de la population et le taux d'usage de stupéfiant. À noter que le taux d'usage de stupéfiant n'est calculé que grâce aux saisies de stupéfiant recensées par départements, ce n'est donc pas un indicateur réel de l'usage de stupéfiant. Nous avons trouvé les deux premiers sur statistiques locales et le taux d'usage de stupéfiant se trouvait sur le même fichier que les données sur les coups et blessures.




À partir de ces agrégats, nous avons pu établir une base de données diversifiée permettant d'approfondir notre étude des problèmes de sociétés pouvant influencer la criminalité en France et déterminer les statistiques principales de chaque indicateur pour la France entière que nous pourrions par la suite comparer avec les statistiques de chaque cluster. Pour résumer ses statistiques, nous avons construit un boxplot par agrégat. On observe que pour la plupart, l'écart à la moyenne est assez dis-parâtre donc on a une réel différence d'intensité de chômage, de


criminalité, de pauvreté ou encore d'usage de stupéfiants en France. D'autant plus que pour chaque agrégat, nous trouvons une à 5 valeurs dites « aberrantes » c'est-à-dire étant très différentes des autres. Ces valeurs aberrantes sont toujours situées au-dessus des autres, c'est-à-dire qu'on ne trouve pas de département étant très en dessous de la moyenne en France mais davantage de départements au-dessus. C'est le cas de la Seine Saint-Denis qui représente la valeur maximale de 2 agrégats : le taux de pauvreté et les coups et blessures. D'après l'analyse des agrégats, il semble que le Nord et la région parisienne ressortent davantage parmi d'autres départements ce qui aurait tendance à confirmer notre hypothèse de départ et à ajouter d'autres facteurs d'influence à la criminalité.



Nous avons ensuite utilisé la méthode des k-means pour répartir les départements dans des clusters en fonction des données. Cette méthode permet de créer des groupes d'individus proches entre eux mais éloignés des autres départements dans les autres clusters. Avant toutes choses, comme nos données se présentent sous plusieurs unités, nous avons normalisé nos données ce qui nous permet de pouvoir réaliser des comparaisons plus faciles entre tous les agrégats. Pour que la méthode des K-means soit la plus efficace, nous devons maximiser le coefficient de silhouette.



Répartition en cluster selon la méthode des k-means




Lorsqu'il est maximum, la distance intra-groupe est minimale et la distance inter-groupes est maximale. Ici, le coefficient de silhouette est maximisé pour 2 clusters. Nous aurons donc deux groupes de départements distincts. Le premier comportant 76 départements, a des indicateurs plus faibles que le deuxième qui ne comporte que 20 départements. En moyenne, dans le premier cluster, le nombre de cas de coups et blessures pour 1000 habitants recensés est de 3 alors que pour le second, il est de 4 cas pour 1000. Grâce à cette répartition en 2 clusters, nous pouvons voir que la criminalité est d'autant plus présente dans des départements ayant un fort taux de pauvreté, de chômage et d'usage de stupéfiants mais également une plus grande population.

Étiquettes de lignes	Nombre de	Code département	Moyenne de Moyenne coups et blessures	Moyenne de Population	Moyenne de Taux de chômage	Moyenne de Taux de pauvreté	Moyenne de Taux usage stupéfiant
1	76,0		3,0	464531,1	6,9	14,6	0,0027
2	20,0		4,0	1510042,5	7,5	15,9	0,0049
Total général	96,0		3,2	682346,0	7,0	14,9	0,0031

Enfin, pour étayer notre étude, nous avons utilisé une autre méthode de répartition en différents groupes : la CAH (classification ascendante hiérarchique). Cette méthode, contrairement à la méthode des k-means, perçoit les individus comme des groupes et les agrège en fonction de leur proximité. Elle cherche à minimiser la distance entre les groupes grâce au calcul de la distance euclidienne entre les groupes. De nouveau cette méthode est optimale lorsqu'il n'y a que 2 clusters. Cette fois-ci, le deuxième cluster contenant les individus avec la plus forte criminalité s'est réduit et ne contient plus que 17 départements avec toujours cette forte présence des départements de régions parisienne et du nord mais

Répartition en cluster selon la méthode de la CAH




également du sud-est de la France. De plus, on observe un creusement de l'écart entre les moyennes des indicateurs du premier et du deuxième cluster. Cependant, cet écart n'est pas causé par une diminution de la moyenne des indicateurs du premier cluster qui est identique à celle trouvée par la méthode des k-means. Les individus ayant été rajoutés aux premiers clusters : la Gironde, l'Isère et l'Oise sont donc relativement proches en moyenne des autres départements du cluster 1 sur tous les agrégats.

Cluster :	Nombre de	Nom département	Moyenne de	Moyenne coups et blessures	Moyenne de Population	Moyenne de Taux de chômage	Moyenne de Taux de pauvreté	Moyenne de Taux usage stupéfiant
1	79			3,00	494596,44	6,90	14,53	0,0027
2	17			4,07	1554829,06	7,61	16,49	0,0051
Total général	96			3,19	682345,97	7,03	14,88	0,0031

La méthode de la CAH réalisée avec Xlstat, nous permet également d'obtenir une matrice détaillant la corrélation entre les différentes variables. Avec la première colonne, nous pouvons voir la corrélation entre nos 4 agrégats et la criminalité. On remarque que ces coefficients sont tous relativement proches (autour de 0,575). Néanmoins, le taux de pauvreté semble avoir une plus grande corrélation avec la criminalité puisque le coefficient est entre les deux de 0,585, même si cette différence est minime elle reste à prendre en compte.

from \ to	Moyenne coups et blessures
Moyenne coups et blessures	1
Population	0,574
Taux de chômage	0,575
Taux de pauvreté	0,585
Taux usage stupéfiant	0,577



En conclusion, grâce à ces différentes méthodes d'analyse, nous constatons que la criminalité est principalement présente dans les départements où se trouvent les grandes métropoles françaises. Cette analyse nous a également permis de trouver des explications partielles à cette criminalité, liées à la population, au taux de chômage, au taux de pauvreté et à l'usage de stupéfiants. Toutefois, il serait intéressant d'explorer d'autres facteurs potentiellement vecteurs de criminalité comme la consommation d'alcool ou le nombre de commissariats. Malheureusement, nous ne pourrions jamais connaître toutes les raisons aboutissant à ces violences puisque certains agrégats tels que les décisions politiques ne peuvent être concrètement mesurés.