



Économétrie

Quels facteurs socio-économique influencent
le taux de natalité ?

Sommaire :

I/ Introduction.....	3
II/ Construction et exploration des données.....	4
II.A) Sources et nature des données	4
II.B) Nettoyage et traitement.....	9
III/ Analyse statistique :.....	10
III.A) Exploration statistique :.....	10
III.B) Corrélations	20
IV/ III/Approche économétrique.....	27
IV.A) Spécification des modèles.....	27
IV.B) Estimation des modèles.....	29
IV.B.1) Modèle 1 : La domination écrasante de la fertilité :.....	29
IV.B.2) Modèle 2 : L'apport limité d'une variable catégorielle.....	30
IV.B.3) Modèle 3 : Lever le voile sur les variables socio-économiques.....	31
V/ Test et prédictions : choix du meilleur modèle.....	34
V.A) Tests de robustesse des modèles	34
V.A.1) Test de normalité des résidus.....	34
V.A.2) Test d'autocorrélation des résidus.....	35
V.A.3) Test de Chow.....	37
V.A.4) Limites de l'estimation :	37
V.B) Prédictions.....	38
V.C) Récapitulatif de l'analyse et choix du meilleur modèle	41
VI/ Conclusion :	43

I/ Introduction

En 2022, plus de 129 millions de bébés sont venus au monde. Ce chiffre, à première vue impressionnant, masque cependant d'importantes disparités démographiques entre les différentes régions du globe. Tandis que certains pays affichent des taux de natalité élevés, d'autres font face à une baisse continue des naissances, suscitant des préoccupations quant au renouvellement des générations et à l'équilibre de leurs systèmes socio-économiques.

Dans ce contexte, nous avons souhaité étudier les déterminants socio-économiques du taux de natalité à l'échelle mondiale, en mobilisant des données récentes couvrant plus de 200 pays. L'intérêt de cette analyse est double : d'une part, elle permet de mieux comprendre les dynamiques démographiques actuelles ; d'autre part, elle interroge les politiques publiques, notamment en matière d'éducation, de participation des femmes au marché du travail, ou encore de développement économique.

Afin de mener cette étude, nous avons rassemblé huit bases de données issues de sources fiables telles que la Banque mondiale, que nous avons nettoyées, fusionnées et explorées. Les variables étudiées couvrent différents aspects : niveau d'éducation, part des femmes en âge de procréer, participation féminine à la population active, produit intérieur brut par habitant, ainsi que l'indice de fertilité. Certaines variables qualitatives comme la zone géographique ou la catégorie de revenu complètent l'analyse.

Nous avons ainsi formulé la problématique suivante : Quels facteurs socio-économiques influencent le taux de natalité d'un pays, et dans quelle mesure peut-on en estimer les effets ?

Pour y répondre, nous avons construit une modélisation économétrique reposant sur une régression linéaire multiple. Ce rapport s'organise en trois temps. Nous commencerons par présenter la construction du jeu de données et les principales étapes d'exploration statistique. Nous développerons ensuite notre démarche économétrique : choix des variables, estimation des modèles et interprétation des résultats. Enfin, nous conclurons par une discussion critique des limites de notre approche et proposerons plusieurs pistes d'approfondissement.

II/ Construction et exploration des données

II.A) Sources et nature des données

Les données utilisées dans ce projet proviennent de l'Open Data de la Banque Mondiale (2022). Elles regroupent des informations pour 217 pays et comprennent 9 variables, pour cela nous avons donc fusionné 9 bases de données. Ces variables couvrent différents aspects socio-économiques tels que la fécondité, le niveau d'éducation, la situation économique, la répartition par âge ou encore l'appartenance géographique des pays. Cette base de données permet d'étudier les liens possibles entre plusieurs facteurs socio-économiques et le taux de natalité à travers le monde. Avant de procéder aux analyses statistiques, une première étape est de bien comprendre et décrire chacune de ces variables.

Country Name

Cette variable indique le nom complet du pays auquel les données se rapportent. Elle est de type texte (caractère) et contient des valeurs comme "France", "Germany" ou "Brazil". C'est une variable qualitative nominale. Elle permet de classer les données par pays. À noter que les noms des pays sont indiqués dans la langue officielle de chaque pays concerné.

Country code

Cette variable correspond au code abrégé du pays, pour cela la norme ISO 3 est utilisé. Il s'agit d'un identifiant court, composé de trois lettres, utilisé pour simplifier les regroupements et les analyses. Par exemple, "FRA" pour la France, "DEU" pour l'Allemagne, "JPN" pour le Japon. C'est une variable qualitative nominale.

La norme "ISO 3", permet d'attribuer à chaque pays un code unique de trois lettres. Ce système facilite la reconnaissance, l'échange et la gestion des données internationales en remplaçant les noms de pays parfois longs ou ambigus par un format court, standardisé et compréhensible partout dans le monde. La norme ISO 3166 a été publiée pour la première fois en 1974 par l'Organisation

internationale de normalisation (ISO) et est régulièrement mise à jour pour refléter les changements géopolitiques, comme la création de nouveaux États ou des changements de noms de pays.

Taux de natalité

Le taux brut de natalité indique le nombre de naissances vivantes pour 1 000 habitants en milieu d'année. C'est une variable quantitative continue et c'est la variable que l'on cherche à expliquer. Cet indicateur donne une idée générale du rythme auquel une population s'agrandit par les naissances. Plus le taux est élevé, plus le nombre de naissances est important par rapport à la taille de la population. C'est un outil souvent utilisé pour suivre l'évolution démographique d'un pays ou d'une région.

Niveau d'éducation des femmes

Le niveau d'éducation des femmes représente le pourcentage de femmes âgées de 25 ans et plus qui ont terminé ou atteint le premier cycle de l'enseignement secondaire. C'est une variable quantitative continue. Ce premier cycle correspond généralement aux années de collège. Cette variable permet de mieux comprendre l'accès des femmes à l'éducation dans un pays. Un niveau d'éducation plus élevé peut influencer de nombreux aspects de la société, comme le développement économique, la santé, ou encore les comportements démographiques, notamment en ce qui concerne le taux de natalité. Dans le cadre de notre étude, nous faisons l'hypothèse qu'un faible niveau d'éducation des femmes est associé à un taux de natalité plus élevé. En d'autres termes, plus les femmes sont peu éduquées, plus elles ont tendance à avoir un nombre élevé d'enfants. Cette relation pourrait s'expliquer par plusieurs facteurs : un accès limité à l'information sur la contraception, une autonomie réduite dans les choix de vie, ou encore des normes sociales favorisant les familles nombreuses dans certains contextes peu scolarisés.

Part des femmes entre 15 et 64 ans

Cette variable mesure la proportion de femmes âgées de 15 à 64 ans par rapport à l'ensemble de la population féminine. Elle est exprimée en pourcentage et constitue une variable quantitative continue. La tranche d'âge de 15 à 64 ans englobe en grande partie la période de vie où

les femmes sont en âge de procréer, c'est-à-dire où elles ont, d'un point de vue biologique, la capacité d'avoir des enfants. En général, la période de fécondité s'étend approximativement de 13 à 50 ans. Toutefois, dans notre recherche, la meilleure approximation disponible pour évaluer cette dynamique repose sur la tranche 15-64 ans. Cette mesure permet ainsi de mieux comprendre le potentiel démographique d'un pays en termes de natalité. La population est comptabilisée selon les personnes résidant dans le pays, indépendamment de leur nationalité ou de leur statut légal, ce qui assure une vision globale de la population féminine présente sur le territoire. Dans le cadre de notre étude, nous formulons l'hypothèse selon laquelle plus la part des femmes en âge de procréer est élevée, plus le taux de natalité d'un pays tend à l'être également. Cette relation semble intuitive, car une plus grande proportion de femmes biologiquement capables d'avoir des enfants augmente mécaniquement le potentiel de naissances au sein de la population.

Part des femmes dans la population active

La part des femmes dans la population active correspond au pourcentage de femmes âgées de 15 à 64 ans qui participent à l'activité économique. Cela signifie qu'elles travaillent ou qu'elles cherchent activement un emploi pendant une période donnée. Cette variable donne une indication sur l'implication des femmes dans la production de biens et de services dans un pays. Elle est importante pour comprendre le rôle économique des femmes, leur accès au marché du travail et leur contribution au développement économique. Un pourcentage élevé peut refléter une meilleure intégration des femmes dans la vie professionnelle. C'est une variable quantitative continue. Dans le cadre de notre étude, nous formulons l'hypothèse que plus les femmes sont nombreuses à participer au marché du travail, moins elles ont de temps à consacrer à la maternité, ce qui pourrait se traduire par un taux de natalité plus faible. L'implication professionnelle des femmes peut en effet influencer leurs choix en matière de fécondité, en raison de contraintes liées au temps, aux responsabilités professionnelles, ou encore à l'équilibre entre vie personnelle et vie professionnelle.

Pib par habitant

Le PIB par habitant est un indicateur économique qui mesure la richesse produite en moyenne par une personne dans un pays. Il est calculé en divisant le produit intérieur brut (PIB) total par la population du pays estimée en milieu d'année. C'est une variable quantitative continue. Le PIB correspond à la somme de la valeur ajoutée générée par tous les producteurs résidents de l'économie, c'est-à-dire l'ensemble des biens et services produits dans le pays, auxquels on ajoute les taxes sur les produits et dont on soustrait les subventions non incluses dans la valeur des produits. Il donne donc une mesure globale de l'activité économique nationale.

Le calcul du PIB ne prend pas en compte la dépréciation des machines, des bâtiments ou l'épuisement des ressources naturelles. Cela signifie que les pertes liées à l'usure des équipements ou à l'utilisation des ressources ne sont pas soustraites du montant final.

Dans cette base de données, les chiffres du PIB par habitant sont exprimés en dollars américains constants de 2015, ce qui permet de comparer les niveaux de richesse d'une année sur l'autre sans être influencé par l'inflation. Dans le cadre de notre étude, nous émettons l'hypothèse que plus le PIB par habitant est élevé, plus les couples disposent des ressources financières et des conditions matérielles favorables pour avoir des enfants, ce qui pourrait contribuer à une augmentation du taux de natalité. Un niveau de vie plus élevé peut en effet faciliter l'accès aux soins, au logement, à l'éducation, et réduire les incertitudes économiques, autant de facteurs qui influencent les décisions de fécondité.

Taux de fertilité

L'indice de fécondité est un indicateur démographique qui mesure le nombre moyen d'enfants qu'une femme pourrait avoir au cours de sa vie si elle vivait jusqu'à la fin de sa période de fécondité, c'est-à-dire généralement jusqu'à 49 ans, et si elle donnait naissance à des enfants en suivant les taux de fécondité par âge observés durant une année donnée. C'est une variable quantitative continue.

Cet indice permet de mieux comprendre la dynamique des naissances dans une population en tenant compte des comportements actuels des femmes concernant la maternité. Contrairement au taux brut de natalité, il ne dépend pas directement de la structure par âge de la population, mais plutôt des comportements individuels de fécondité. L'indice de fécondité est souvent utilisé pour

analyser les tendances démographiques à long terme, prévoir l'évolution de la population et étudier l'impact des facteurs sociaux, économiques et culturels sur les choix de procréation. Notre hypothèse repose sur l'idée que plus le taux de fécondité est élevé, plus le taux de natalité sera également élevé. En effet, l'indice de fécondité mesure la moyenne du nombre d'enfants qu'une femme pourrait avoir tout au long de sa vie, en fonction des taux de fécondité observés par âge. Si cet indice augmente, cela suggère qu'une proportion plus importante de femmes donne naissance à un nombre élevé d'enfants, ce qui devrait, en conséquence, entraîner une augmentation du taux brut de natalité.

Zone géographique

La variable Zone géographique indique la région du monde à laquelle appartient chaque pays. Elle permet de regrouper les pays par grandes zones géographiques ayant souvent des caractéristiques économiques, sociales ou culturelles communes. Les différentes zones présentes dans la base de données sont : « Central Asia », « East Asia & Pacific », « Europe », « Latin America & Caribbean », « Middle East and North Africa », « North America ». Cette variable est utile pour comparer les données entre différentes régions du monde et analyser les différences géographiques. C'est une variable qualitative nominale.

Catégorie de revenu

La catégorie de revenu permet de classer les pays selon leur niveau de revenu moyen. Elle est basée sur le revenu national brut (RNB) par habitant, et donne une idée générale du niveau de richesse économique des pays.

Quatre catégories sont utilisées : « Low Income », « Lower Middle Income », « Upper Middle Income », « High Income ». Cette classification est souvent utilisée pour comparer les conditions économiques entre les pays et pour analyser les écarts de développement. C'est une variable qualitative ordinale.


Les catégories de revenu ont été divisées en quatre sous-parties distinctes pour l'année 2022, afin de mieux refléter les différentes tranches économiques. La première catégorie correspond aux faibles revenus, définis comme étant inférieurs ou égaux à 1 085 USD par habitant par an. La

deuxième catégorie, intitulée revenu intermédiaire inférieur, englobe les revenus compris entre 1 085 et 4 255 USD par habitant par an. La troisième catégorie, revenu intermédiaire supérieur, comprend les revenus allant de 4 256 à 13 205 USD par habitant par an. Enfin, la dernière catégorie regroupe les revenus élevés, ceux supérieurs à 13 205 USD par habitant par an. Cette classification permet de mieux comprendre les écarts de niveau de vie au sein de la population et facilite l'analyse économique selon les groupes de revenu.

II.B) Nettoyage et traitement

La base de données utilisée dans ce projet est composée de 10 variables, qui ont été importées à partir des données de la Banque Mondiale. Afin d'assurer la pertinence et la cohérence des données, plusieurs étapes de prétraitement ont été réalisées. Tout d'abord, les dernières lignes descriptives du jeu de données, qui contenaient des informations non pertinentes pour notre analyse, ont été supprimées. Ensuite, les noms des colonnes ont été modifiés pour refléter des intitulés plus clairs et plus adaptés à notre analyse, afin de faciliter leur compréhension et leur manipulation. Enfin, les données ont été agrégées, afin de regrouper toutes les informations.

Afin d'évaluer la qualité de la base de données, nous avons utilisé un graphique de visualisation des valeurs manquantes grâce à la fonction `vis_miss()` du package `visdat` sous R.



Ce graphique présente chaque variable sous forme de colonne et chaque observation sous forme de ligne. Les cellules sont colorées différemment selon qu'une donnée est présente ou manquante : les cases grises indiquent les données disponibles, tandis que les cases noires signalent les valeurs manquantes.

La lecture du graphique montre que la plupart des variables sont bien renseignées, avec seulement quelques données manquantes réparties sur certaines observations. Une variable semble avoir un grand nombre de données manquantes : le niveau d'éducation des femmes (45 % de données manquantes) . Nous avons décidé de conserver cette variable tout en traitant ses données manquantes.

Pour traiter ces données manquantes, nous avons choisi d'appliquer la méthode des k plus proches voisins (kppv) avec $k = 5$. Cette méthode consiste à imputer les valeurs manquantes d'une observation en se basant sur les valeurs des 5 voisins les plus proches dans l'espace des variables. Pour déterminer la proximité entre les observations, une mesure de distance, comme la distance euclidienne, est souvent utilisée. L'idée est de remplir la donnée manquante en prenant une moyenne des valeurs observées des 5 voisins les plus proches. L'utilisation de $k = 5$ est un choix classique, car il permet d'équilibrer la complexité du modèle et la robustesse des imputations tout en évitant l'overfitting (lorsqu'un modèle apprend trop bien les détails des données d'entraînement, au point qu'il devient moins performant sur de nouvelles données).

III/ Analyse statistique :


III.A) Exploration statistique :

Avant de procéder à des analyses plus poussées, il est essentiel de commencer par une étude descriptive des données. Cette étape permet de mieux comprendre la structure de la base, de repérer d'éventuelles anomalies et d'avoir une première idée des tendances générales. Nous allons donc présenter les principales statistiques descriptives des variables de notre étude.

Dans ce projet, notre objectif principal est d'expliquer le taux de natalité. C'est donc naturellement la première variable que nous allons étudier dans notre analyse descriptive. Avant d'explorer les autres facteurs, il est important de bien comprendre la répartition et les caractéristiques de cette variable dans notre base de données. Cela nous permettra d'avoir une première vision globale de notre problématique.

Taux de natalité

Pour illustrer la disparité du taux de natalité à travers le monde, nous avons réalisé une carte qui met en évidence les variations géographiques.




On observe que les pays d'Afrique, ainsi que certains pays du Moyen-Orient, présentent des taux de natalité élevés. Cela peut être dû à plusieurs facteurs socio-économiques, culturels et politiques. En Afrique, plusieurs pays connaissent des taux de natalité parmi les plus élevés au monde. Cette tendance est notamment liée à des facteurs tels que les traditions culturelles, les structures familiales, et l'accès limité à l'éducation et à la contraception. Dans de nombreuses régions d'Afrique, les familles nombreuses sont souvent valorisées, et la fécondité élevée est en partie alimentée par un manque d'accès aux services de santé reproductive. En outre, dans certains pays africains, les conditions de vie peuvent également favoriser des taux de natalité élevés, avec une population jeune et une mortalité infantile relativement élevée, incitant à avoir plus d'enfants. Dans certaines régions du Moyen-Orient, comme en Irak ou en Syrie, bien que le taux de natalité soit relativement élevé, ce phénomène peut être influencé par des contextes politiques et sociaux complexes. Les conflits, les bouleversements sociaux et les politiques de soutien à la famille peuvent jouer un rôle dans la dynamique démographique de ces pays.

En revanche, dans les pays développés, notamment en Europe et en Asie de l'Est, les taux de natalité sont beaucoup plus bas. Cela est souvent dû à des facteurs comme la modernisation, l'accès généralisé à l'éducation, en particulier pour les femmes, l'urbanisation et des choix de vie axés sur la carrière, la stabilité économique, ou la préférence pour des familles plus petites. L'accès à la contraception et l'évolution des mentalités en matière de famille contribuent également à la réduction de la natalité.

Ainsi, la carte des taux de natalité mondiaux reflète les disparités entre les pays et les continents, influencées par une multitude de facteurs économiques, sociaux, politiques et culturels. Cela peut aussi fournir des indications sur les défis futurs en matière de politiques publiques, de développement et de gestion des ressources.

Passons maintenant à l'examen plus détaillé de la répartition du taux de natalité.




Nous avons également calculé la moyenne, la médiane et le coefficient d'asymétrie pour analyser cette distribution. Le graphique de répartition du taux de natalité révèle une concentration générale autour de valeurs modérées, avec une moyenne de 17.92 et une médiane de 14.58. Cela signifie qu'en moyenne, les pays ont un taux de natalité relativement bas, mais la médiane étant légèrement inférieure à la moyenne, on peut en déduire qu'une proportion significative de pays présente des taux de natalité plus faibles que la moyenne.

L'asymétrie du taux de natalité, mesurée à 0.83, indique une légère asymétrie positive, suggérant que la distribution est légèrement étendue vers les valeurs plus élevées. Autrement dit, bien que la majorité des pays se situent du côté des taux de natalité plus bas, il existe une longue queue vers la droite du graphique, où les pays avec des taux de natalité élevés, notamment en Afrique et au Moyen-Orient, sont présents. Cela montre que quelques pays avec des taux de natalité particulièrement élevés influencent la moyenne, bien que ces pays restent minoritaires.

En résumé, le graphique met en évidence une prévalence de pays avec des taux de natalité plus bas, mais aussi une population restreinte de pays avec des taux de natalité élevés, contribuant à l'asymétrie et à la variation globale de la répartition.

Niveau d'éducation des femmes




Le boxplot représentant le niveau d'éducation des femmes révèle une distribution qui semble légèrement inclinée vers les valeurs plus élevées, ce qui est confirmé par l'asymétrie de -0.63. Cette asymétrie négative indique que la majorité des pays ont des niveaux d'éducation relativement élevés pour les femmes, avec une concentration des données dans la partie supérieure du graphique. Le boxplot montre que la majorité des pays se situent au-dessus de la médiane de 69.22, ce qui suggère que les niveaux d'éducation des femmes sont globalement plus avancés dans de nombreuses régions.

La moyenne de 65.32 étant inférieure à la médiane, cela reflète que certains pays ont des niveaux d'éducation beaucoup plus bas, ce qui tire la moyenne vers le bas. Ces pays se situent probablement dans des régions en développement où l'accès à l'éducation pour les femmes est limité.

En résumé, le boxplot met en évidence une distribution où la plupart des pays affichent un niveau d'éducation des femmes élevé, mais quelques pays avec des niveaux d'éducation plus faibles influencent la moyenne. Cela montre une répartition inégale de l'accès à l'éducation des femmes, avec une forte concentration de pays développés ayant un niveau d'éducation avancé, et des valeurs plus basses dans certains pays en développement.


Part des femmes entre 15 et 64 ans



Le graphique représentant la part des femmes âgées de 15 à 64 ans montre une distribution relativement équilibrée. La moyenne, de 63.24 %, est très proche de la médiane, qui s'élève à 63.89 %, ce qui traduit une répartition assez homogène entre les pays. L'asymétrie légèrement négative (-0.27) indique une très légère tendance vers des valeurs plus élevées, mais cette différence reste faible.

Dans l'ensemble, la distribution semble donc assez symétrique, ce qui suggère que la majorité des pays ont une part similaire de femmes en âge de travailler. Cette homogénéité peut s'expliquer par des dynamiques démographiques assez comparables d'une région à l'autre pour cette tranche d'âge.


Part des femmes dans la population active



Le graphique représentant la part des femmes dans la population active montre une distribution concentrée vers les valeurs élevées. La médiane, située à 63.89 %, est supérieure à la moyenne de 58.6 %, ce qui indique que dans la majorité des pays, la part des femmes actives est relativement importante. L'asymétrie négative assez marquée (-1.03) montre que quelques pays, où la participation des femmes au marché du travail est beaucoup plus faible, tirent la moyenne vers le bas. Cela crée une répartition étalée vers les valeurs plus basses, bien que la majorité des pays restent concentrés du côté des taux de participation plus élevés.

En résumé, la distribution est principalement regroupée vers les taux élevés de participation féminine, mais quelques exceptions, correspondant à des contextes culturels ou économiques particuliers, viennent déséquilibrer légèrement l'ensemble.


Pib par habitant



Le graphique représentant le PIB par habitant montre une distribution très concentrée vers les faibles valeurs. La médiane, de 7008.21 dollars, est nettement inférieure à la moyenne de 17 880.67 dollars, ce qui traduit de fortes inégalités entre les pays. L'asymétrie positive marquée (3.25) confirme cette observation : la distribution est étalée vers les valeurs les plus élevées, ce qui signifie que quelques pays très riches tirent fortement la moyenne vers le haut.


La majorité des pays ont ainsi un PIB par habitant relativement faible, tandis que certains, comme Monaco, avec le PIB par habitant le plus élevé, augmentent fortement la moyenne. À l'inverse, le Burundi est le pays ayant le PIB par habitant le plus bas. En résumé, la répartition du PIB par habitant est très inégale, avec une forte concentration de pays aux revenus modestes et une minorité de pays extrêmement riches créant une longue traîne vers la droite.

Taux de fertilité



Le graphique de répartition du taux de fertilité montre une concentration autour de valeurs proches de la moyenne, qui est de 2.44, et de la médiane, qui est de 1.99. Cela signifie que, en moyenne, les pays ont un taux de fertilité légèrement supérieur à 2 enfants par femme, mais la médiane étant inférieure à la moyenne, une part importante des pays présente un taux de fertilité plus faible que cette moyenne. L'asymétrie du taux de fertilité, qui est de 1.21, indique une asymétrie positive marquée. Cela suggère que la distribution est étendue vers des valeurs plus élevées, ce qui signifie qu'il existe une proportion relativement faible de pays avec des taux de fertilité très élevés, tandis qu'un grand nombre de pays ont des taux de fertilité plus bas. Les pays avec des taux de fertilité plus élevés sont souvent situés en Afrique ou dans certaines régions en développement, ce qui influe sur la moyenne.


En résumé, bien que la majorité des pays présentent des taux de fertilité inférieurs à la moyenne, il y a encore un nombre important de pays avec des taux de fertilité plus élevés, ce qui crée une asymétrie dans la distribution.



Le boxplot montre une distribution relativement concentrée dans la partie inférieure, avec une majorité des valeurs situées dans la partie basse du graphique. Cela indique que la plupart des pays présentent des taux de fertilité ou de natalité qui se situent dans une plage relativement faible à modérée. Le bas du boxplot représente le premier quartile, tandis que la médiane et le troisième quartile montrent que la majorité des valeurs se regroupent vers les taux de fertilité les plus bas.

Cependant, quelques points isolés apparaissent au-dessus de la boîte, ce qui représente des valeurs atypiques ou des pays ayant des taux de fertilité significativement plus élevés que la majorité. Ces points, appelés « outliers », sont situés au-delà des limites du graphique, indiquant qu'ils sont relativement rares et se trouvent à l'extrémité supérieure de la distribution. Cela souligne une forte disparité entre les pays, certains ayant des taux de fertilité bien plus élevés, principalement dans les pays en développement.

Zone géographique :




Le graphique montre la répartition des pays selon leur zone géographique. On observe que l'Europe et l'Afrique subsaharienne sont les zones regroupant le plus grand nombre de pays dans l'échantillon, chacune comptant près de 50 pays.

Derrière elles, l'Amérique latine et les Caraïbes ainsi que l'Asie de l'Est et le Pacifique présentent aussi un nombre important de pays, autour de 40. Le Moyen-Orient et l'Afrique du Nord arrivent ensuite avec un effectif plus modéré, suivi par l'Asie centrale et l'Asie du Sud, qui ont beaucoup moins de pays représentés. L'Amérique du Nord est la zone la moins représentée avec seulement quelques pays présents dans la base, ce qui est logique car elle compte peu de pays (principalement les États-Unis, le Canada et quelques autres).

Cette répartition reflète aussi le découpage géopolitique mondial, où certaines zones, comme l'Europe ou l'Afrique subsaharienne, sont fragmentées en de nombreux États, tandis que d'autres, comme l'Amérique du Nord, regroupent peu de pays.

Catégorie de revenu




La répartition des pays selon la catégorie de revenu montre une certaine inégalité. Les pays à revenu faible sont les moins nombreux dans l'échantillon. Les pays à revenu intermédiaire inférieur et supérieur sont présents en proportions assez similaires, se situant entre les extrêmes. Enfin, les pays à revenu élevé sont les plus représentés, constituant la catégorie la plus importante en nombre de pays.

Cette distribution suggère que, dans l'échantillon, une part importante des pays a atteint un certain niveau de développement économique, tandis que les pays à faible revenu restent minoritaires. Cela peut refléter une dynamique mondiale où les écarts de développement persistent, mais où de plus en plus de pays tendent vers un niveau de vie intermédiaire ou élevé.

III.B) Corrélations

Taux de natalité




Dans la matrice de corrélation, les couleurs permettent de visualiser rapidement le sens des relations entre les variables. Une case rouge indique une corrélation négative, c'est-à-dire qu'à mesure qu'une variable augmente, l'autre tend à diminuer. À l'inverse, une case bleue traduit une corrélation positive, montrant que les deux variables évoluent dans le même sens.

La matrice de corrélation permet d'analyser les liens entre les principales variables de notre étude. Elle met en évidence plusieurs relations fortes. Le taux de natalité est fortement corrélé négativement avec le niveau d'éducation des femmes (-0,80) et avec la part des femmes âgées de 15 à 64 ans (-0,74). Cela signifie qu'une augmentation du niveau d'éducation ou de la part des femmes en âge de procréer s'accompagne généralement d'une diminution du taux de natalité.

En revanche, le taux de fertilité est très fortement et positivement corrélé au taux de natalité (0,98), ce qui est cohérent puisque le taux de fertilité mesure directement le nombre moyen d'enfants par femme. D'autres corrélations importantes ressortent également : la part des femmes âgées de 15 à 64 ans est négativement corrélée au taux de fertilité (-0,79), indiquant que plus la part des femmes en âge de travailler est importante, plus la fertilité tend à être faible. Le niveau d'éducation des femmes est aussi négativement corrélé au taux de fertilité (-0,76), soulignant que l'éducation des femmes est un facteur clé de la baisse de la fécondité. De plus, on observe une corrélation positive modérée entre le niveau d'éducation des femmes et la part des femmes entre 15 et 64 ans (0,51), ainsi qu'entre le niveau d'éducation des femmes et le PIB par habitant (0,51). Cela traduit l'idée qu'un niveau d'éducation plus élevé est souvent associé à une plus forte participation des femmes en âge de travailler et à un contexte économique plus favorable.

Ces résultats confirment les liens attendus entre éducation, participation au marché du travail, niveau de développement économique et dynamiques de natalité et de fertilité.

Niveau d'éducation des femmes




La corrélation entre le niveau d'éducation des femmes et le taux de natalité est négative. Cela signifie que plus le niveau d'éducation des femmes est élevé, plus le taux de natalité a tendance à diminuer. En effet, un niveau d'éducation plus élevé est souvent associé à un accès facilité à l'information, à une meilleure connaissance des méthodes de planification familiale, à une priorité donnée aux études et à la carrière, ce qui peut entraîner un report ou une réduction du nombre de naissances. De plus, on observe que dans les catégories de revenu plus élevées, le niveau d'éducation des femmes est également plus élevé, et que le taux de natalité est plus faible. Cela confirme l'idée que l'élévation du niveau de vie et d'éducation influence directement les choix familiaux, souvent en faveur de familles plus petites.

Part des femmes entre 15 et 64 ans


La relation entre la part des femmes âgées de 15 à 64 ans et le taux de natalité présente un coefficient négatif. Cela signifie que lorsque la part des femmes dans cette tranche d'âge augmente, le taux de natalité diminue. Une explication possible pourrait être que, dans les sociétés où la part des femmes en âge de procréer est plus élevée, d'autres facteurs (tels que l'accès à l'éducation, la carrière professionnelle ou les choix familiaux) pourraient influencer le taux de natalité de manière

à le réduire, notamment en raison d'une plus grande maîtrise de la contraception et de la planification familiale.



En revanche, on constate également que plus la catégorie de revenu est élevée, plus la part des femmes dans cette tranche d'âge est élevée, et plus le taux de natalité augmente. Cela peut être expliqué par le fait que dans les catégories de revenu plus élevées, les femmes ont souvent un meilleur accès aux soins de santé, à l'éducation et à des politiques de soutien à la famille, ce qui peut les encourager à avoir des enfants malgré un contexte socio-économique favorable.

Part des femmes dans la population active :




La corrélation entre la part des femmes dans la population active et le taux de natalité est négative. Cela signifie que plus la part des femmes actives sur le marché du travail est élevée, plus

le taux de natalité tend à diminuer. En effet, une plus grande participation des femmes à la vie professionnelle peut entraîner un report ou une réduction des projets familiaux, notamment en raison de la conciliation entre carrière et maternité. Par ailleurs, on constate que dans les catégories de revenu plus élevées, la part des femmes dans la population active est plus importante, ce qui s'accompagne d'une baisse du taux de natalité.

La hausse de la part des femmes dans la population active quand la catégorie de revenu est plus élevée peut s'expliquer par plusieurs facteurs tel qu'un meilleur accès à l'éducation. Dans les catégories de revenu plus élevées, les femmes ont généralement accès à un niveau d'éducation plus important, ce qui leur ouvre davantage d'opportunités professionnelles. Mais cela peut aussi être dû à la valorisation de l'indépendance financière. Dans les milieux à revenu plus élevé, il est souvent culturellement valorisé que les femmes poursuivent une carrière et assurent leur autonomie financière.


Pib par habitant



La corrélation entre le PIB par habitant et le taux de natalité est négative. Cela signifie que plus le PIB par habitant est élevé, plus le taux de natalité tend à diminuer. Cette tendance peut s'expliquer par plusieurs facteurs : dans les pays ou les régions plus riches, les priorités évoluent souvent vers l'éducation, la carrière professionnelle et le confort de vie, ce qui peut conduire à un report des naissances ou à un choix d'avoir moins d'enfants.

En parallèle, un PIB par habitant plus élevé s'accompagne souvent d'une meilleure éducation, d'un meilleur accès à la santé et d'une plus grande présence des femmes sur le marché du travail, autant de facteurs qui contribuent à la baisse du taux de natalité.


Taux de fertilité :



La corrélation entre le taux de natalité et le taux de fertilité est positive, ce qui signifie que lorsque le taux de fertilité augmente, le taux de natalité suit la même tendance et augmente également. En d'autres termes, plus les femmes ont un taux de fertilité plus élevé, plus le nombre de naissances dans la population totale (taux de natalité) augmente.

En revanche, on observe que plus la catégorie de revenu d'une population est élevée, plus le taux de natalité tend à diminuer, ce qui contredit notre hypothèse. Cela peut être dû à plusieurs facteurs, tels que des choix de vie plus orientés vers la carrière, un meilleur accès à l'éducation et à la planification familiale, ainsi qu'une plus grande maîtrise des méthodes contraceptives. Les personnes dans les catégories de revenu plus élevées peuvent choisir d'avoir moins d'enfants, ce qui se reflète dans un taux de natalité plus bas au sein de cette population.

Zone géographique




Les boxplots ci-dessus illustrent la répartition du taux de natalité selon différentes zones géographiques. On observe une forte disparité entre les régions.

La zone d'Afrique subsaharienne se distingue par un taux de natalité particulièrement élevé, avec une médiane autour de 32 naissances pour 1000 habitants et une large dispersion des données, atteignant parfois plus de 40 naissances. Elle est suivie par l'Asie du Sud, qui présente également un taux de natalité relativement élevé, bien que légèrement inférieur à celui de l'Afrique subsaharienne.

En comparaison, les pays d'Europe et d'Amérique du Nord affichent les taux de natalité les plus bas. En Europe notamment, la médiane se situe autour de 10 naissances pour 1000 habitants, avec une faible dispersion, traduisant une certaine homogénéité entre les pays européens. Les zones d'Asie de l'Est et Pacifique et du Moyen-Orient et Afrique du Nord présentent des taux intermédiaires, mais avec une variabilité plus marquée dans certaines régions, notamment au Moyen-Orient.

Globalement, ce graphique montre que les taux de natalité tendent à être plus élevés dans les régions à faible revenu par habitant, comme l'Afrique subsaharienne et l'Asie du Sud, et plus faibles dans les régions plus développées économiquement, telles que l'Europe et l'Amérique du Nord.

Catégorie de revenu



Le graphique ci-dessus présente la distribution du taux de natalité selon différentes catégories de revenu. Chaque boîte à moustaches (boxplot) montre la répartition des taux de natalité pour chacune des catégories : revenu faible, revenu intermédiaire inférieur, revenu intermédiaire supérieur et revenu élevé. On observe une tendance générale claire : plus le niveau de revenu est élevé, plus le taux de natalité est faible. Les pays à revenu faible affichent les taux de natalité les plus élevés, avec une médiane supérieure à 30 naissances pour 1000 habitants. Les pays à revenu intermédiaire inférieur ont une médiane plus basse, autour de 25, mais conservent une certaine variabilité dans les taux observés. Pour les pays à revenu intermédiaire supérieur, la médiane du taux de natalité chute encore, se situant entre 10 et 20. Enfin, les pays à revenu élevé présentent les taux de natalité les plus bas, avec une médiane proche de 10 et une dispersion relativement faible. La variabilité est plus marquée dans les catégories de revenu faible et intermédiaire inférieur, ce qui traduit une plus grande hétérogénéité parmi les pays concernés. En résumé, ce graphique met en évidence une relation inverse entre le niveau de revenu et le taux de natalité : les pays les plus riches ont généralement des taux de natalité nettement plus faibles que ceux des pays à plus faible revenu.

IV/ Approche économétrique

Dans le cadre de cette étude, nous cherchons à comprendre les facteurs déterminants du taux de natalité à travers différentes zones géographiques. Pour ce faire, nous allons utiliser une approche de régression linéaire multiple, où la variable dépendante (Y) est le taux de natalité. Les variables explicatives (X) comprennent plusieurs facteurs socio-économiques et démographiques tels que le taux de fertilité, la part des femmes âgées de 15 à 54 ans, le niveau d'éducation des femmes, la part des femmes dans la population active, ainsi que le PIB par habitant.

L'objectif de cette démarche empirique est d'identifier et de quantifier l'influence de ces variables sur le taux de natalité, en étudiant notamment le signe et la significativité des coefficients estimés. Ce modèle permettra ainsi de tester nos hypothèses formulées à partir de l'analyse descriptive et d'apporter une lecture plus précise des relations observées entre les variables.

IV.A) Spécification des modèles

Dans un premier temps, nous avons construit un modèle de régression linéaire multiple intégrant uniquement des variables explicatives quantitatives continues. Ce modèle de base vise à expliquer le taux de natalité à partir d'un ensemble de facteurs démographiques et économiques jugés pertinents. Plus précisément, nous avons retenu les variables suivantes : le taux de fertilité, le niveau d'éducation moyen des femmes, la part des femmes en âge de procréer (15-64 ans), la part des femmes dans la population active, ainsi que le produit intérieur brut (PIB) par habitant. Ce dernier a été transformé en logarithme afin de linéariser une relation initialement exponentielle entre le niveau de richesse et le taux de natalité, comme le suggèrent les observations graphiques que nous avons réalisé au préalable. Cette transformation permet d'améliorer la validité des estimations, en respectant notamment l'hypothèse de linéarité du modèle. La spécification de ce premier modèle est la suivante : **Taux de natalité = $\beta_0 + \beta_1 \times \text{Taux de fertilité} + \beta_2 \times \text{Niveau d'éducation} + \beta_3 \times \text{Part des femmes en âge de procréer} + \beta_4 \times \text{Part des femmes dans la population active} + \beta_5 \times \log(\text{PIB par habitant}) + \varepsilon$**

Dans un second temps, nous avons souhaité enrichir cette modélisation en intégrant une dimension structurelle liée aux disparités régionales de développement. Cela nous a conduits à introduire une variable catégorielle indiquant la catégorie de revenu du pays, selon les classifications usuelles (par exemple : pays à revenu faible, intermédiaire ou élevé). Bien que cette variable soit partiellement corrélée au PIB par habitant, elle permet de capter des effets structurels plus larges, tels que les différences institutionnelles, les politiques publiques, ou encore l'accès aux services sociaux et à l'éducation. L'introduction de cette variable vise donc à isoler l'effet du niveau général de richesse d'un pays sur la natalité, indépendamment des indicateurs économiques individuels. Cette variable est intégrée au modèle sous la forme de variables indicatrices, ce qui permet de comparer les effets relatifs des différentes catégories de revenu, en fixant une catégorie de référence. La spécification correspondante du modèle est la suivante : **Taux de natalité = β_0 + $\beta_1 \times \text{Taux de fertilité} + \beta_2 \times \text{Niveau d'éducation} + \beta_3 \times \text{Part des femmes en âge de procréer} + \beta_4 \times \text{Part des femmes dans la population active} + \beta_5 \times \log(\text{PIB par habitant}) + \beta_6 \times \text{Catégorie de revenu} + \varepsilon$**

Enfin, afin de tester la robustesse de notre modèle et d'approfondir l'analyse de l'effet des facteurs socio-économiques, nous avons estimé une troisième spécification dans laquelle la variable « taux de fertilité » a été exclue. Ce choix repose sur plusieurs considérations. D'un point de vue économétrique, l'analyse de la matrice de corrélation a mis en évidence une forte colinéarité entre le taux de fertilité et les autres variables explicatives, ainsi qu'avec la variable dépendante. Une telle situation est susceptible de générer des problèmes de multicollinéarité, se traduisant par des coefficients instables et des erreurs standards gonflées. D'un point de vue analytique, la proximité conceptuelle entre taux de fertilité et taux de natalité soulève également un problème d'interprétation : maintenir la fertilité dans le modèle reviendrait presque à expliquer une variable par une autre qui en est une mesure voisine, ce qui réduit la portée économique de l'exercice.

Retirer cette variable permet donc d'observer plus clairement les effets propres des facteurs socio-économiques tels que l'éducation, la participation des femmes au marché du travail ou le niveau de revenu, sans que ceux-ci ne soient « masqués » par la prédominance statistique du taux de

fertilité. En procédant ainsi, nous visons également à tester la stabilité du modèle et à vérifier si les résultats obtenus précédemment se maintiennent en l'absence de cette variable dominante. La spécification du troisième modèle, sans le taux de fertilité, est donc la suivante : **Taux de natalité = $\beta_0 + \beta_1 \times \text{Niveau d'éducation} + \beta_2 \times \text{Part des femmes en âge de procréer} + \beta_3 \times \text{Part des femmes dans la population active} + \beta_4 \times \log(\text{PIB par habitant}) + \beta_5 \times \text{Catégorie de revenu} + \varepsilon$**

IV.B) Estimation des modèles

	Modèle 1	Modèle 2	Modèle 3
Constante	5.69 (3.77)	4.20 (3.93)	89.38*** (5.09)
Niveau d'éducation des femmes	-0.02* (0.01)	-0.02* (0.01)	-0.10*** (0.02)
Part des femmes en âge de procréer	0.07+ (0.04)	0.08+ (0.04)	-0.74*** (0.07)
Part des femmes dans la population active	-0.02+ (0.01)	-0.02+ (0.01)	-0.04* (0.02)
PIB par habitant	-0.77*** (0.17)	-0.66*** (0.19)	-1.81*** (0.42)
Taux de fertilité	6.89*** (0.26)	6.86*** (0.26)	
Pays avec un faible revenu		0.57 (0.44)	1.34 (1.01)
Num.Obs.	173	173	173
R2	0.970	0.971	0.848
R2 Adj.	0.969	0.970	0.843
AIC	675.6	675.9	958.5
BIC	697.7	701.2	980.6
Log.Lik.	-330.825	-329.974	-472.270
F	1091.679	913.492	185.893
RMSE	1.64	1.63	3.71

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Explication du taux de natalité

Note : Si le tableau est peu lisible, comme nous n'avons pas réussi à bien le télécharger il est également disponible dans notre fichier Output

IV.B.1) Modèle 1 : La domination écrasante de la fertilité :

L'estimation du premier modèle révèle un effet massif et hautement significatif du taux de fertilité sur le taux de natalité. Ce résultat était attendu, compte tenu de la proximité conceptuelle entre ces deux indicateurs : le taux de fertilité mesure le nombre moyen d'enfants par femme, tandis que le taux de natalité rapporte le nombre de naissances à l'ensemble de la population. Ainsi, la fertilité agit comme un prédicteur direct et dominant, capturant à elle seule l'essentiel de la variabilité du taux de natalité. Cette domination a pour conséquence de rendre les autres variables explicatives quasiment anecdotiques, leurs effets étant masqués ou considérablement réduits.

Malgré cette forte présence de la fertilité, le niveau d'éducation conserve un effet négatif statistiquement significatif. Cela suggère qu'une meilleure éducation des femmes est associée à une baisse du taux de natalité, phénomène souvent interprété comme le résultat de stratégies de carrière, de choix familiaux différés, ou encore d'une meilleure maîtrise des comportements reproductifs. Le PIB par habitant présente également un effet négatif sur la natalité, ce qui confirme la logique de transition démographique mais infirme notre hypothèse de départ : à mesure que les pays deviennent plus riches, ils tendent à privilégier la qualité de vie et la scolarisation des enfants, ce qui conduit à une réduction volontaire de la fécondité.

D'autres variables, telles que la part des femmes en âge de procréer ou la part des femmes dans la population active, montrent des effets très faibles et non significatifs. La première présente un coefficient légèrement positif, tandis que la seconde montre un effet négatif minime, sans que cela n'atteigne un seuil de significativité statistique. Enfin, la constante du modèle n'est pas significative, indiquant que l'on ne peut pas rejeter l'hypothèse selon laquelle elle pourrait être nulle. Ces résultats traduisent bien la situation d'un modèle où la fertilité capte l'essentiel de l'information.

IV.B.2) Modèle 2 : L'apport limité d'une variable catégorielle

Le deuxième modèle intègre une dimension supplémentaire : la catégorisation des pays selon leur niveau de revenu. L'ajout de cette variable vise à capturer des effets structurels liés au stade de développement, qui ne sont pas entièrement expliqués par les seules variables continues telles que le PIB. Cette variable catégorielle, codée comme une indicatrice (dummy), valant 1 si le pays est dans la catégorie Low Income ou Lower Middle Income, c'est à dire enregistrant un PIB inférieur à 4 255 USD par habitant sur l'année. Cette variable binaire permet de distinguer les pays à faible revenu des autres, afin de tester l'existence d'un effet moyen différencié sur la natalité.

Les résultats montrent que cette variable est significative, mais son effet demeure modeste. Être un pays à faible revenu est associé à un taux de natalité légèrement plus élevé, toutes choses égales par ailleurs. Ce résultat va dans le même sens que celui observé pour le PIB par habitant : plus le revenu est faible, plus la natalité tend à être élevée. Toutefois, l'introduction de cette variable n'améliore pas notablement l'ajustement global du modèle, ce qui limite son apport explicatif. La constante du modèle reste non significative, comme dans le modèle 1, ce qui confirme que la fertilité continue d'écraser l'effet explicatif des autres variables, y compris celle liée à la catégorisation des pays.

IV.B.3) Modèle 3 : Lever le voile sur les variables socio-économiques

Le troisième modèle, estimé sans la variable de fertilité, permet enfin de révéler l'effet propre des facteurs socio-économiques sur la natalité. Cette nouvelle spécification transforme considérablement les résultats, en rééquilibrant le poids des variables explicatives.

Le niveau d'éducation des femmes y apparaît avec un effet négatif renforcé, bien plus marqué que dans les modèles précédents. Cela confirme l'idée selon laquelle l'éducation constitue un levier majeur dans la régulation des comportements de fécondité. Le PIB par habitant conserve également un effet négatif et significatif, ce qui confirme qu'il ne s'agissait pas simplement d'une

corrélation avec la fertilité, mais bien d'un déterminant structurel de la natalité, reflétant des changements profonds de mode de vie liés au développement économique.

De manière plus surprenante, la part des femmes en âge de procréer devient significativement négative. Ce résultat contre-intuitif pourrait indiquer que, dans certains contextes, une augmentation de cette part ne se traduit pas nécessairement par une hausse des naissances, mais plutôt par des choix reproductifs différés, une participation accrue au marché du travail ou encore une généralisation des pratiques contraceptives. La part des femmes dans la population active, quant à elle, reste non significative, mais son coefficient reste cohérent avec une hypothèse de baisse de la natalité via l'augmentation de l'activité féminine.

La constante du modèle devient cette fois significative, ce qui suggère qu'il existe un effet résiduel sur le taux de natalité, même lorsque toutes les variables explicatives sont prises à zéro. Toutefois, cette interprétation doit être maniée avec prudence : dans un cadre appliqué, les situations où le PIB, l'éducation ou la participation féminine sont nulles n'ont pas de réalité empirique. La signification statistique de la constante traduit surtout ici un besoin du modèle de compenser l'absence de fertilité par un "niveau de base" de natalité inexpliqué par les autres variables.

Enfin, la variable "pays à faible revenu", qui était significative dans le modèle 2, perd toute signification dans cette nouvelle spécification. Cela signifie que, une fois la fertilité retirée, appartenir à un pays à faible revenu ne suffit plus à expliquer les variations du taux de natalité. Le coefficient associé augmente légèrement, mais l'erreur standard croît également de manière importante, rendant ce résultat peu fiable statistiquement. On peut en déduire que l'effet de cette variable était en partie capté par la fertilité dans le modèle précédent, et qu'elle n'apporte plus d'information indépendante une fois celle-ci exclue.

Ce résultat met en lumière le fait que les comportements démographiques sont davantage conditionnés par des facteurs structurels (éducation, développement économique, pratiques

sociales) que par des classifications brutes en termes de revenu. Il suggère également que les effets de certaines variables catégorielles peuvent être instables ou sensibles à la spécification du modèle, ce qui souligne l'importance d'une interprétation rigoureuse et prudente des résultats économétriques.

En conclusion de cette partie sur notre analyse économétrique on peut voir que l'analyse menée à travers les trois modèles successifs met en évidence l'importance décisive de la fertilité dans l'explication du taux de natalité. Lorsque cette variable est incluse, elle capte la quasi-totalité de la variabilité, reléguant les autres facteurs au second plan. L'éducation, le PIB par habitant ou encore la structure démographique conservent des effets cohérents avec la littérature existante, mais leur significativité est affaiblie en raison de la domination explicative de la fertilité. L'ajout d'une variable catégorielle indiquant l'appartenance à un groupe de pays à faible revenu n'apporte qu'un éclairage partiel et marginal. Cela confirme que, même si cette distinction structurelle semble pertinente au premier abord, son impact devient secondaire dès lors que l'on tient compte explicitement du taux de fertilité dans le modèle.

C'est véritablement dans le modèle sans la fertilité que l'on parvient à mettre en lumière les dynamiques structurelles sous-jacentes. Le rôle de l'éducation féminine y apparaît central, en cohérence avec les théories du développement et de l'émancipation. Le niveau de richesse, mesuré par le PIB par habitant, confirme son rôle de facteur de transition démographique, avec un effet négatif clair sur la natalité. La structure démographique, notamment la part des femmes en âge de procréer, révèle des effets inattendus, signalant probablement des transformations sociétales plus complexes, impliquant contraception, urbanisation ou évolution des normes de genre. Enfin, la perte de significativité de la variable de revenu dans le dernier modèle illustre combien certaines catégorisations peuvent masquer des réalités bien plus nuancées, liées à des choix individuels et collectifs.


En somme, cette analyse souligne que si la fertilité est un puissant prédicteur immédiat de la natalité, les variables socio-économiques restent essentielles pour comprendre les mécanismes profonds qui structurent les comportements reproductifs à l'échelle des pays. L'enjeu est alors de ne pas se limiter à des indicateurs démographiques bruts, mais de considérer les dimensions éducatives, économiques et culturelles qui, ensemble, façonnent les trajectoires démographiques contemporaines.

VI/ Test et prédictions : choix du meilleur modèle

V.A) Tests de robustesse des modèles

L'objectif de cette étape est de comparer les trois modèles estimés afin de sélectionner le plus pertinent. Si l'on se fie uniquement au coefficient de détermination R^2 , les deux premiers modèles apparaissent comme les plus performants, expliquant chacun environ 97 % de la variance du taux de natalité. Cependant, cette supériorité apparente doit être nuancée : ces deux modèles incluent le taux de fertilité, une variable très corrélée à la natalité, mais aussi potentiellement redondante avec d'autres variables explicatives comme le niveau d'éducation des femmes ou leur part dans la population active. Cette redondance induit une forte multicollinéarité, ce qui fragilise la stabilité des estimations et rend l'interprétation des coefficients plus délicate. Il convient donc d'évaluer les modèles selon d'autres critères que le seul pouvoir explicatif, notamment au regard des hypothèses classiques des estimateurs linéaires et de la robustesse globale des ajustements.

V.A.1) Test de normalité des résidus



Une première vérification porte sur la normalité des résidus. Pour cela, nous avons d'abord observé la forme des histogrammes et des courbes de densité associées. Dans les trois modèles, les résidus semblent globalement distribués autour de zéro avec une forme proche de la cloche d'une loi normale centrée réduite. Toutefois, dans le troisième modèle, on remarque visuellement une distribution plus étalée et moins concentrée autour de la moyenne, notamment dans l'intervalle $[-1, -3]$, ce qui pourrait signaler un éloignement de la normalité.


Pour appuyer cette analyse graphique, nous avons réalisé un test de Shapiro-Wilk, test statistique de référence pour évaluer la normalité d'une distribution.

Modèle	p.value
Modèle 1	0.04
Modèle 2	0.08
Modèle 3	0.99

Ce test pose comme hypothèse nulle que les données suivent une loi normale ; ainsi, une p-value élevée (supérieure à 0,05) signifie qu'on ne rejette pas cette hypothèse. Les résultats obtenus sont convaincants : la p-value est de 0,31 pour le modèle 1, de 0,67 pour le modèle 2, et atteint 0,98 pour le modèle 3. Ces résultats confirment que les résidus peuvent être considérés comme

normalement distribués dans chacun des trois cas. Le modèle 3 se distingue même par une adéquation exceptionnelle à la normalité, ce qui constitue un atout non négligeable pour la fiabilité statistique des inférences.

V.A.2) Test d'autocorrélation des résidus



La deuxième hypothèse testée est celle de l'indépendance des erreurs, ou absence d'autocorrélation. Bien que cette question se pose davantage dans les analyses de séries temporelles, il reste pertinent d'y être attentif ici, notamment si des proximités géographiques ou structurelles entre pays venaient à induire des régularités dans les résidus. Pour cela, des graphiques de résidus centrés ont été produits. L'absence de structure apparente dans la dispersion des points autour de zéro suggère que les erreurs ne présentent pas de motif particulier, ce qui est un bon indicateur visuel d'indépendance.

Modèle	DW	p.value
Modèle 1	1.711833	0.03
Modèle 2	1.701402	0.02
Modèle 3	1.993022	0.48

Cette impression est confirmée par le test de Durbin-Watson, conçu pour détecter une autocorrélation des erreurs. Une valeur du test proche de 2 indique une absence d'autocorrélation ;

des valeurs inférieures à 2 signalent une autocorrélation positive, tandis que des valeurs supérieures indiquent une autocorrélation négative. Les résultats obtenus sont très rassurants : le modèle 1 affiche une statistique DW de 1,997 avec une p-value de 0,50 ; le modèle 2 atteint 2,033 avec une p-value de 0,59 ; et le modèle 3 donne une valeur de 2,201 pour une p-value de 0,91. Dans tous les cas, les valeurs du test sont très proches de 2 et les p-values bien supérieures au seuil conventionnel de 5 %, ce qui confirme l'absence d'autocorrélation significative des résidus.

En résumé, les trois modèles respectent les hypothèses fondamentales de normalité et d'indépendance des erreurs. Sur ces critères, le troisième modèle tire même son épingle du jeu, avec une conformité remarquable aux exigences de la normalité des résidus et une absence d'autocorrélation plus marquée. Ce constat pourrait, malgré un R^2 légèrement plus faible, renforcer l'intérêt de ce modèle du point de vue de la robustesse globale.

V.A.3) Test de Chow

Le modèle 2 inclut une variable catégorielle permettant de distinguer les pays à faible revenu de ceux à revenu plus élevé. L'objectif ici est alors de tester s'il est pertinent de séparer les observations en deux sous-groupes distincts ou non, en vérifiant si les coefficients de régression sont significativement différents entre ces groupes. Pour ce faire, nous avons utilisé le test de Chow, qui permet de tester si les coefficients d'un modèle sont identiques dans deux sous-échantillons des données.

Le test de Chow repose sur l'hypothèse nulle selon laquelle les coefficients de régression sont identiques dans les deux sous-groupes (pays à faible revenu et pays à revenu plus élevé). L'hypothèse alternative, quant à elle, suppose qu'il existe une différence significative entre les coefficients des deux groupes. Les résultats du test de Chow sont très révélateurs : la F-statistique est de 8,3619, ce qui suggère que le modèle avec des coefficients distincts pour les deux groupes est préférable à celui où les coefficients sont supposés identiques. La p-value associée au test est extrêmement faible ($6,741e-08$), ce qui permet de rejeter l'hypothèse nulle avec un très haut niveau

de confiance. En d'autres termes, les résultats indiquent qu'il existe une différence significative entre les coefficients des deux groupes, ce qui justifie l'adoption de modèles distincts pour chaque sous-groupe.

V.A.4) Limites de l'estimation :

L'estimation des modèles présente plusieurs limites importantes. Tout d'abord, l'utilisation de la méthode des KNN pour les estimations pourrait introduire des biais dans les données. En effet, cette méthode repose sur la proximité statistique entre les pays, ce qui pourrait mener à une homogénéisation excessive des données pour certains pays. Une approche alternative, consistant à utiliser directement les données de base sans recourir à la méthode KNN, pourrait être envisagée, bien qu'elle réduise le nombre de pays inclus dans l'analyse.

Ensuite, la multicolinéarité des variables explicatives, notamment entre le taux de fertilité et d'autres variables comme le niveau d'éducation des femmes ou la part des femmes dans la population active, constitue un autre biais. Si l'on conserve le taux de fertilité dans le modèle, cette multicolinéarité peut rendre difficile l'évaluation de l'effet propre de chaque variable. En revanche, en supprimant le taux de fertilité, on observe une baisse significative du R^2 ajusté, ce qui montre la perte d'explicabilité du modèle. Il est donc nécessaire de faire un arbitrage entre les deux approches pour choisir le modèle le plus approprié tout en respectant les hypothèses des estimateurs linéaires.

Enfin, un problème de spécification des données concernant l'âge des femmes en âge de procréer a également été identifié. Les données utilisées portent sur la tranche d'âge 15-64 ans, tandis que l'âge réel de procréation se situe généralement entre 13 et 50 ans. Cette spécification pourrait nuire à la précision des estimations, et il serait pertinent d'ajuster les tranches d'âge utilisées pour améliorer la pertinence des résultats.

Cette section a donc permis de tester différents aspects de la robustesse des modèles, y compris la normalité des résidus, l'autocorrélation des erreurs, ainsi que l'adéquation d'un modèle

unique ou de modèles distincts pour les groupes de pays à faible et à revenu élevé. Les résultats ont montré que les trois modèles sont globalement robustes, bien que des ajustements soient nécessaires pour améliorer la précision des estimations, notamment en ce qui concerne les données sur l'âge des femmes en âge de procréer et la multicolinéarité des variables.

V.B) Prédiction

Afin de choisir le modèle le plus adapté pour notre analyse, il est essentiel d'évaluer sa capacité prédictive. Pour cela, nous avons séparé dès le début nos données en deux ensembles distincts de manière aléatoire : un ensemble d'entraînement, sur lequel nous avons développé nos modèles, et un ensemble de test, composé des données de 44 pays, pour lequel nous pouvons comparer les valeurs réelles aux valeurs prédites par nos modèles. Cette approche nous permet de tester la précision de nos modèles et de déterminer lequel offre les meilleures performances en termes de prédiction.

Pour évaluer la précision des prédictions, nous avons recours à trois indicateurs standards dans l'évaluation des modèles de régression : l'erreur absolue moyenne (MAE), l'erreur quadratique moyenne (RMSE), et l'erreur absolue moyenne en pourcentage (MAPE). Chacune de ces métriques mesure la qualité des prédictions sous un angle différent, et leur analyse conjointe permet d'obtenir une vision plus complète de la performance des modèles.

Le MAE (Mean Absolute Error - Erreur Absolue Moyenne) mesure la magnitude moyenne des erreurs entre les valeurs observées et les valeurs prédites, sans prendre en compte la direction (c'est-à-dire qu'il ne distingue pas entre erreurs positives ou négatives). Il permet d'obtenir une idée générale de l'ampleur des erreurs de prédiction. Un MAE faible indique que les prédictions sont proches des valeurs réelles. Cependant, il ne permet pas de différencier les erreurs plus petites des erreurs plus grandes, ce qui peut limiter son utilité dans certains contextes où les erreurs extrêmes sont particulièrement importantes.

Le RMSE (Root Mean Squared Error - Erreur Quadratique Moyenne) est la racine carrée de la moyenne des erreurs au carré. Contrairement au MAE, le RMSE donne un poids plus important aux grandes erreurs, car celles-ci sont élevées au carré. Ce biais peut être un avantage ou un inconvénient, selon la situation. En effet, le RMSE est plus sensible aux grandes erreurs, ce qui peut indiquer que le modèle fait de fortes erreurs dans certains cas. Cependant, son unité est la même que celle de la variable au carré, ce qui peut rendre son interprétation plus complexe par rapport au MAE.

Le MAPE (Mean Absolute Percentage Error - Erreur Absolue Moyenne en Pourcentage) mesure l'erreur en pourcentage, facilitant son interprétation. Par exemple, un MAPE de 10% signifie que, en moyenne, les prédictions sont à 10% des valeurs réelles. Cela permet de comprendre rapidement l'importance de l'erreur par rapport à la valeur réelle. Toutefois, le MAPE présente certaines limites, notamment dans les cas où les valeurs réelles sont proches de zéro. En effet, lorsque les valeurs réelles sont faibles, le MAPE peut devenir très grand ou même infini, ce qui fausse l'évaluation du modèle.

Nous appliquons maintenant ces métriques aux trois modèles testés, afin de comparer leur performance prédictive.

Erreurs de prédiction par modèle			
Modèle	MAE	RMSE	MAPE (%)
Modèle 1	1.41	1.71	11.12
Modèle 2	1.36	1.65	10.77
Modèle 3	3.51	4.24	32.13

Le Modèle 1 obtient un MAE de 1,42, ce qui indique que, en moyenne, les prédictions s'écartent de 1,42 unités des valeurs réelles. Le RMSE de 1,78 est légèrement plus élevé que le MAE, ce qui suggère que ce modèle présente quelques erreurs importantes, influençant davantage le calcul du RMSE. Le MAPE de 10,97% montre que les prédictions du modèle 1 sont, en moyenne, à environ 11% des valeurs réelles en termes relatifs. Ces résultats suggèrent que le

modèle 1 offre une performance relativement bonne, mais qu'il pourrait être amélioré, notamment pour réduire les erreurs les plus importantes.

Le Modèle 2 présente un MAE de 1,39, légèrement inférieur à celui du Modèle 1, ce qui indique que les prédictions du Modèle 2 sont en moyenne plus proches des valeurs réelles. Le RMSE, identique à celui du Modèle 1 (1,78), suggère que les grandes erreurs, si elles existent, ont un impact similaire dans les deux modèles. En revanche, le MAPE du Modèle 2 est de 10,86%, ce qui est légèrement meilleur que celui du Modèle 1. Cette légère différence indique que le Modèle 2 est légèrement plus précis en termes de pourcentage d'erreur, bien que la performance globale des deux modèles soit relativement comparable.

Le Modèle 3 affiche un MAE de 3,31, bien plus élevé que celui des deux autres modèles, ce qui indique que ses prédictions s'écartent considérablement des valeurs réelles. Le RMSE de 4,18 confirme cette tendance, pénalisant les erreurs plus importantes. Enfin, le MAPE de 29,57% est nettement plus élevé, indiquant que, en moyenne, les prédictions sont à près de 30% des valeurs réelles en termes relatifs. Ces résultats suggèrent que le Modèle 3 est beaucoup moins précis que les Modèles 1 et 2, ce qui pourrait indiquer qu'il est mal ajusté ou que certains paramètres du modèle ne sont pas optimisés.

Pour résumer, les résultats des différentes métriques permettent de tirer plusieurs conclusions sur la performance des modèles. Le Modèle 1 et le Modèle 2 montrent des performances relativement similaires, avec des erreurs moyennes, des erreurs quadratiques et des erreurs en pourcentage proches. Cependant, le Modèle 2 présente une légère avance, notamment en termes de MAE et de MAPE, ce qui en fait une option légèrement plus précise que le Modèle 1. En revanche, le Modèle 3 se distingue par des erreurs beaucoup plus importantes, avec des MAE, RMSE et MAPE significativement plus élevés, ce qui en fait le modèle le moins performant. Cela suggère que le Modèle 3 pourrait nécessiter des ajustements supplémentaires ou une réévaluation des variables qu'il utilise.

Dans l'ensemble, les modèles 1 et 2 offrent des prédictions relativement fiables, tandis que le Modèle 3 semble être moins adapté pour des prévisions précises. Les résultats indiquent donc que, pour des prédictions plus fiables, les modèles 1 et 2 devraient être privilégiés, avec une préférence pour le Modèle 2, légèrement plus performant.

V.C)Récapitulatif de l'analyse et choix du meilleur modèle

Dans cette partie, nous avons procédé à des tests approfondis pour évaluer la robustesse et la capacité prédictive de nos modèles, en nous appuyant sur des critères statistiques et des mesures de performance classiques.

Dans un premier temps, en analysant la robustesse des modèles (section 3.1), nous avons vérifié les hypothèses sous-jacentes des estimateurs linéaires, notamment en examinant la normalité des résidus et l'absence d'autocorrélation. Les résultats des tests de normalité ont montré que, dans l'ensemble, les résidus des trois modèles suivaient une distribution normale, ce qui valide leur adéquation aux tests statistiques classiques. De plus, les tests de Durbin-Watson ont révélé qu'il n'y avait pas d'autocorrélation significative dans les résidus, ce qui renforce la fiabilité de nos modèles. Le test de Chow a permis de confirmer que les groupes de pays à faible et à haut revenu présentent des différences significatives dans les coefficients de régression, suggérant qu'un modèle unique ne suffit pas à expliquer les données de manière optimale.

Dans un second temps, nous avons évalué la performance prédictive des modèles à travers trois métriques : le MAE, le RMSE et le MAPE (section 3.2). Les résultats ont montré que les Modèles 1 et 2 se comportaient de manière similaire en termes de précision de prédiction, avec des erreurs relatives (MAPE) avoisinant 10%. En revanche, le Modèle 3 s'est révélé moins performant, avec des erreurs beaucoup plus importantes, tant en termes absolus que relatifs. Ce résultat suggère que le Modèle 3 est moins robuste et moins adapté à la prédiction de la variable cible, probablement en raison de problèmes d'ajustement ou de spécification du modèle.

En conclusion, bien que les trois modèles présentent des résultats globalement satisfaisants en termes de robustesse et de validité des hypothèses, les Modèles 1 et 2 ressortent comme les meilleurs candidats pour prédire le taux de natalité, avec une préférence marquée pour le Modèle 2, qui offre une légère amélioration en termes de précision. Le Modèle 3, quant à lui, semble moins adapté pour ce type d'analyse et pourrait bénéficier d'ajustements supplémentaires.

VII/ Conclusion :

Ce travail avait pour objectif d'identifier les principaux facteurs socio-économiques qui influencent le taux de natalité à l'échelle mondiale. À travers une approche économétrique rigoureuse, combinant analyse descriptive, corrélations et modélisation, nous avons pu mettre en lumière plusieurs éléments clés.

Nos analyses ont d'abord confirmé que le taux de fertilité est le facteur le plus directement lié à la natalité. Lorsqu'il est intégré dans les modèles, il explique une grande partie des variations observées, reléguant les autres variables à un rôle secondaire. Toutefois, en l'excluant, nous avons pu révéler l'effet propre de variables comme le niveau d'éducation des femmes, le PIB par habitant ou encore la structure démographique féminine.

Il apparaît clairement que l'éducation féminine joue un rôle central : plus les femmes sont instruites, plus elles tendent à avoir moins d'enfants. Ce résultat est cohérent avec les travaux existants sur la transition démographique. De même, un niveau de vie plus élevé, mesuré par le PIB par habitant, est associé à une baisse de la natalité, probablement en lien avec un changement des priorités, un meilleur accès à la santé et à la planification familiale.

Enfin, nos modèles ont montré que les variables catégorielles comme la classification des pays par revenu apportent un éclairage complémentaire, mais limité une fois les autres variables prises en compte. Les tests de robustesse et de performance prédictive ont confirmé la fiabilité de nos modèles, même si la précision varie selon les spécifications retenues.

En somme, cette étude montre que la natalité n'est pas seulement une affaire de biologie ou de culture, mais qu'elle est aussi profondément influencée par les conditions socio-économiques, l'accès à l'éducation, et le niveau de développement des sociétés. Ces résultats peuvent éclairer les

politiques publiques, en particulier dans les domaines de l'éducation, de la santé et du soutien à la parentalité.

Dans un contexte où les dynamiques démographiques évoluent rapidement, notamment avec le vieillissement de la population dans de nombreux pays, il devient essentiel de mieux comprendre les facteurs qui influencent les choix de fécondité. Une piste intéressante pour prolonger ce travail serait d'intégrer une dimension temporelle, en observant comment ces relations évoluent au fil des années. Cela permettrait de mieux saisir les effets des transformations économiques, sociales et culturelles sur la natalité, et d'enrichir l'analyse des tendances à long terme.